

从统计学的角度看看双色球到底有没有被“操纵”？ ——用 python 分析过去 15 年 2354 期双色球数据

YYB

注：本文不提供任何关于双色球的购买意见，单纯从统计角度看看双色球的分布，只图一乐
本文会涉及到一点点统计学知识，
完全不懂的同学只需了解一下关于 p 值的知识，（以下解释不准确，但不妨碍理解）
如果 $p < 0.05$ ，说明某件事可能不是纯随机发生的，可能背后有某种原因或规律。
如果 $p > 0.05$ ，很可能只是随机发生的，没有明显的规律。

一、起因：一个数据分析菜鸡的“偏执”

在跑 NGS 的时候，偶然打开知乎，发现有人发了个贴：你见过最大的骗局是什么？
下面的高赞回答：“统计了过去五年**双色球奖池高位和低位的时候，中奖率差别竟然可达将近两倍**，存在显著差异！肯定是官方找了托，让人来清理高位奖池！来收大众智商税”。

上高中的时候也买过好几次双色球，幻想过中 500 万但都失败之后，感觉非常相信知乎高赞回答，并姑且称之为【**高位奖池清空学说**】。但作为一个数据分析员，不能听风就是雨，抱着怀疑的态度，打开了中国福利彩票网站，把 2003 年到 2023 年的全部开奖数据都爬了下来，搞了一千行 Python 代码，做了一个完整的统计学分析。来看看到底双色球的数据符不符合科学。（代码实锤党请放心，全过程都有日志记录，文末也会附上完整 python 代码。）

一、数据概览：2354 期，2008001 期到-2023082 期

首先，我的分析范围覆盖了：

📅 时间跨度：2008 年 1 月 1 日到 2023 年 7 月 18 日

📦 数据总量：2354 期双色球开奖

为什么我不用 2003 年开始的数据呢？因为爬下来的数据发现 05 年以前的数据中一等奖的注数和奖金有很多缺失，且年代久远通货膨胀严重，影响分析，所以就取了 08-23 年的数据（以下随手截了部分 03 和 19 年的数据，可以发现 03 年后面的奖金数据很多都是 0，因此舍去）。

1	序号	开奖日期	期号	红球1	红球2	红球3	红球4	红球5	红球6	蓝球	销售额	一等奖注数	一等奖奖金	二等奖注数	二等奖奖金	三等奖注数	三等奖奖金	奖池(元)
2238	2237	2003/9/25	2003062	1	6	12	19	20	32	14	40972030	0	0	0	0	0	0	0
2239	2238	2003/9/21	2003061	3	5	20	21	28	32	2	38065358	0	0	0	0	0	0	0
2240	2239	2003/9/18	2003060	2	4	6	17	21	28	11	35595266	0	0	0	0	0	0	0
2241	2240	2003/9/14	2003059	2	3	5	6	18	30	4	33611668	0	0	0	0	0	0	0
2242	2241	2003/9/11	2003058	9	11	16	28	32	33	2	31985104	0	0	0	0	0	0	0

1	序号	开奖日期	期号	红球	红球	红球	红球	红球	红球	蓝球	销售额	一等奖注数	一等奖奖金	二等	二等奖金	奖池 (元)
1739	1738	2019-05-02(四)	2019049	4	6	10	13	22	23	2	338779314	13	6332483	203	65197	1307402000
1740	1739	2019-05-02(四)	2019050	4	6	10	11	21	23	2	311858860	13	6136790	100	184728	1300906020
1741	1740	2019-05-05(日)	2019051	8	9	10	13	15	28	9	371316762	13	5503869	120	68232	1276546288
1742	1741	2019-05-07(二)	2019052	3	6	9	13	16	19	16	342251970	153	5117604	2295	9800	1229559631
1743	1742	2019-05-09(四)	2019053	4	16	22	25	29	31	8	345533966	12	5969643	109	133437	514041918

二，先分析一下中奖概率，以及红球，蓝球的分布合理吗？

理论上，学过高中数学的都知道，红色球是 33 个选 6 个，蓝色球是 16 个选 1 个，那么双色球一等奖的中奖概率是：

$$\text{理论中奖率 } P = 1 / (C(6, 33) * C(1, 16)) = 1 / 17,721,088 = 0.000000564$$


我计算 2000 多期的真实中奖率时，实际中奖率为：0.000000566

理论比率：1.0026 倍（几乎一模一样！）


下图是两千多期真实中奖率的柱状图，横坐标表示期号，蓝色柱表示当期真实中奖率，绿色虚线表示真实平均中奖率，红色虚线表示理论中奖率（这里由于两者数值过于接近，一部分被绿色覆盖掉了）。

此图证明**中奖率没有问题**。

（卡方检验 $p = 0.702$ ，远远大于 0.05。没发现可疑迹象，真的挺随机。）



接下来我们来看看红蓝球出现的概率是否合理呢？



我统计了 33 个红球和 16 个蓝球在全部开奖中的出现次数。

如果完全随机，每个红球号码理论上大概出现 $2354 \times 6/33 \approx 428$ 次。

如上方两图，横坐标表示球的号码，纵坐标表示出现次数，虚线表示理论平均出现次数。

其中红球出现次数最少的 33 号，383 次，最多的则是 26 号，472 次。

卡方检验， $p=0.137$ ，虽然不大，但也说明红球出现符合随机效应。

蓝球同理，理论上每个球平均出现 147 次，其中最高 1 号球出现 168 次，最少 13 号球出现 132 次，卡方检验 $p=0.749$ ，蓝球也完全符合随机出现。

那可能还存在对此有次质疑的小伙伴，没关系我还对中奖率的连续分布进行了游程检验 (Runs Test)， $p=0.322$ 。说明中奖分布的确是随机的。（这里规定了超过理论中奖率为+，低于则为-，不知道游程检验的小伙伴可以自行学习一下）

因此，目前可以得出结论，不像是有人为操纵的痕迹，就算有操纵，说明 ta 很懂统计！

三、接下来终于要分析，在奖池金额不同的情况下，中奖率真的有差异吗？！

我把所有开奖期次分成两组：

- 🟢 奖池低（25%以下，共 589 期）
- 💰 奖池高（75%以上，共 589 期）

理论上没人操作的时候，奖池大小不该影响中奖几率。

如果有，应该是奖池高时中奖率更高。也就是前文提到的【高位奖池清空学说】。


统计结果如下，啪啪打脸！（实际平均中奖率 5.66×10^{-8} ）

项目	平均中奖率	描述
奖池低组	5.72×10^{-8}	比平均略高
奖池高组	6.00×10^{-8}	同样略高

t 检验 p 值为 0.439！没有统计学意义上的差异！

换成人话：当奖池高的时候，中一等奖的概率比低奖池略高一点，但不显著（下图）。根本没有知乎上说的那么玄乎。

且两者都比平均中奖率高，也就是说反而奖池大小为中不溜的时候，中奖率最低，【高位奖池清空学说】被否定。



这不是打咱们阴谋论者的脸吗！


但是抱着不服输的态度，我提出了另外一种可能：

如果让我来操纵，那肯定不是在奖池金额一变大，马上就找托清理奖池，这样也太明显了！而是会操作一下，让奖池慢慢涨个几期十几期的没人中一等奖，然后来一发大的，直接清空！。也就是说奖池在持久高位的时候连续没人中奖，将高位奖池的平均中奖率拉低，最后一把才会被托给清理下去！于是就会导致，整体的高位奖池和低位奖池中奖率差异不大于是乎我把我自己提出的猜想，称之为【末端奖池清空学说！】

而刚刚的数据显示，的确奖池高低位中奖率差别不大，好像一定程度上证明了我的猜测，那么怎么样才能进一步来验证这个【末端奖池清空学说！】是否准确呢？

四、果然！奖池大≠中奖多，中奖多=奖池大？！

我想到了如下方法：根据单期一等奖注数不同，分成了下面几组，超过 50 注，20-49 注，10-19 注，10 注以内，以及无一等奖的期次，把相应的奖池金额统计出来对比一下！如果出现超过 50 注，或者 20-49 注一等奖期次的奖池金额很大的话，应该是属于我提出的【末端奖池清空学说】的情况了。结果如下：



如上图，结果显示，全 2354 期双色球的平均奖池 6.54 亿（图中未显示），而一等奖注数超过 50 注的期次的平均奖池高达 7.09 亿，10-19 注和 20-49 注的平均奖池金额也分别高达 7.51 亿和 7.59 亿。而没有一等奖的期次中，平均奖池金额只有 3.72 亿。并且有差异显著（p 几乎等于 0，ANOVA 检验）。


这不明摆着欺负人吗！

也就是说，

一等奖中奖数多的那几期，就是奖池比较多时候。

这不完全证明了我的提出了“末端清空高位奖池”猜想嘛！。

另外，我还做了 15 年内奖池金额随时间的变化图，来侧面证明我的猜想！



可以看到，随着咱们东大过去十五年经济蓬勃发展，总体奖池还是在往上走的，

我在图中标出了过去十五年内**一等奖注数最多的十期（红色圆点）**，可以发现一等奖注数最多的时候，基本都在山顶，**特别是最后三期（153, 73, 74）**，基本上先度过一片高原区，再进行一波末端收割，这强有力的证明了【**末端奖池清空学说！**】。

说到这，好像的确从统计的角度上，好像是“实锤”有人在奖池高位时暗中出手，但是真的是如此吗？！

五、别急！还有反转！


我在做奖池金额随时间的变化图时，顺便一起做了销售额随时间变化的图像（绿色折线）。



不难发现，在奖池高位的时候，基本上销售额也在高位。**符合广大彩民，奖池越大，越要买的博彩心理！**那么！想象一下，奖池在高位时，**如果销售额变高的话，就算中奖率不变的情况下，那中奖注数不也变多了吗？**单纯拿中奖注数最多的几次来说事，是不是故意找茬？

于是我又抛开注数，拿中奖率来分组。

取出中奖率最高的 10%与 20%的期次，和剩下 90%与 80%分别去比较奖池金额，结果如下。



不论是按 10%还是 20%来分类，可以看到高中奖率组和低中奖率组的奖池金额几乎没有差别，p 值也分别高达 0.398 和 0.716，完全不显著。

所以能下这个结论吗：**高奖金伴随的高注数，并不是有操纵，只是高销售额带来的错觉呢？孰对孰错，很难论断。**毕竟统计学只是讲究一个过去事件的总和，讲究的只是一个概率。

真相是什么，我々は神ではない、——引用自李狗嗨

反正我是不知道，原数据和原代码都放在文末的 `github` 链接，希望大家多多支持！

大家可以各显神通，自行分析。

六、尾声：数据不会说谎，但人的解读会

最后说说自己的想法，

都是同样的数据，大家可以看到在不同的章节，可以解读出完全不同的意思。

所以研究数据也好，研究其他也罢，警惕“脑子没动，屁股先行”！

网上有句话玩笑话很流行，“千万不要让实验结果影响你的实验结论！”

虽然是句玩笑话，希望大家还是能“脑子先动，屁股再挪”。

对于任何数据和所见的“事实”，要明辨是非，学会自己去判断。maybe 就是学习的意义吧

本篇推文大家就当看着乐就行了。

啦啦啦啦

附：分析代码与数据来源

项目环境：Python 3.10，脚本里还做了其他许多分析，这边就不一一列出，有兴趣的同学可以自己跑一跑。

主要库：Pandas, SciPy, Matplotlib

数据来源：中国福利彩票官网（2008 - 2023）<https://www.cwl.gov.cn/>

另外，由于官网显示每一期的双色球奖池金额其实是本期的残留余额，所以在 `ssq_data_clean_adj.csv` 的文件里面，是将所有本期残留奖池金额挪到下一期来分析。当然源数据 `ssq_data_clean.csv` 文件也会附上。
